

Optimisation de Portefeuille Avancée

De l'approche Moyenne-Variance aux Méthodes Non-Convexes (Kurtosis)

Louen MARX
OPT101

3 décembre 2025

Résumé

Pour pallier les limites du modèle Moyenne-Variance (crise 2020), nous implémentons une minimisation du Kurtosis via un algorithme *Sequential Convex Programming* (SCP). Cette gestion des risques extrêmes est validée par comparaison avec les solveurs et une relaxation SDP.

Table des matières

1	Introduction et Contexte du Projet	1
1.1	Défis de scalabilité	2
1.2	Analyse Exploratoire des Données (Stationnarité)	3
1.3	Formulation Mathématique et Résolution	3
1.4	Analyse de Robustesse et Frontière Efficente (Monte Carlo)	3
2	Modélisation Avancée : Minimisation du Kurtosis	4
2.1	Le Défi : La Non-Convexité du Kurtosis	4
2.2	Algorithme SCP (Sequential Convex Programming)	5
2.3	Convergence Numérique et Validation	5
3	Résultats Comparatifs et Allocation	6
3.1	Comparaison des Allocations : Validation Croisée	6
3.2	Performance Financière : L'Épreuve de Réalité	7
4	Approche par Relaxation Convexe (SDP)	8
4.1	Relation Théorique	8
4.2	Résultats et Qualité de la Relaxation	9
5	Conclusion	9

1 Introduction et Contexte du Projet

Le modèle classique de Markowitz, s'appuyant sur la Variance (risque gaussien), s'est révélé insuffisant pour modéliser les rendements réels, notamment lors des crises récentes.

Ce projet a pour but de dépasser l'approche Moyenne-Variance en intégrant les moments d'ordre supérieur (notamment le Kurtosis) pour mieux capturer le risque extrême.

Objectifs Clés

- Tester la robustesse du modèle classique face aux ruptures de régime (données 2016-2020).
- Implémenter un solveur SCP (*Sequential Convex Programming*) pour l'optimisation non-convexe du Kurtosis.
- Comparer les performances (financières et computationnelles) de l'approche SCP aux standards.

Méthodologie

L'implémentation est réalisée en Python sur des données réelles (`yfinance`). Nous utilisons `CVXPY` pour les sous-problèmes convexes et `SciPy` pour le benchmarking. Une attention centrale est portée à la **scalabilité**, le passage à l'échelle (augmentation de n) constituant un verrou majeur pour les méthodes quadratiques classiques.

1.1 Défis de scalabilité

L'un des premiers défis rencontrés est la complexité computationnelle. La Figure 1 illustre l'évolution du temps de résolution en fonction des dimensions du problème (n et m). Ces courbes mettent en évidence une caractéristique fondamentale de l'optimisation quadratique classique : sa complexité algorithmique non-linéaire.

L'analyse détaillée permet de dégager trois observations majeures :

1. **Nature de la Croissance (Polynomiale) :** Que ce soit pour le nombre d'actifs n ou de contraintes m , la progression n'est manifestement pas linéaire. La convexité marquée confirme que la complexité des opérations matricielles (résolution de systèmes KKT) est de l'ordre de $\mathcal{O}(n^3)$. Concrètement, doubler la taille du problème multiplie le temps de calcul par un facteur bien plus important.
2. **Impact conjoint de n et m :** L'analyse spécifique de m (Figure 1b), avec un ratio fixé à $m \approx 1.5n$, montre une dynamique identique. Le temps de résolution reste négligeable jusqu'à $m \approx 1500$ avant de croître exponentiellement pour atteindre 140s à $m = 3000$. Cela confirme que la complexité dépend de la taille globale du système matriciel ($m \times n$) et pas uniquement du nombre de variables d'optimisation.
3. **Identification d'un "Mur de Complexité" :** On distingue deux régimes distincts :
 - Une *zone de confort* pour $n < 1000$ (et $m < 1500$), où le temps reste maîtrisé.
 - Une *zone d'explosion* au-delà, où une augmentation de 33% de la taille provoque une multiplication du temps de calcul par un facteur critique, rendant l'approche standard inadaptée pour la gestion de portefeuilles institutionnels massifs.

Scalabilité financière et Diversification : Au-delà du temps de calcul, l'analyse pour $n = 20$ actifs démontre quantitativement les bénéfices de la diversification. Alors que le portefeuille à 3 actifs présente un écart-type de 16.49% sur la période d'entraînement, celui-ci chute à **10.43%** pour $n = 20$. Cette réduction du risque (d'environ 37%) valide la capacité du modèle à éliminer le risque spécifique lorsque l'univers d'investissement s'élargit, bien que le rendement espéré diminue mécaniquement (de 19.72% à 12.90%).

Comparaison des solveurs (CVXPY vs SLSQP) Il est intéressant de noter la différence de comportement entre les solveurs. Pour les petites dimensions ($n < 500$), `SLSQP` se montre extrêmement rapide grâce à son implémentation bas-niveau optimisée. Cependant, `CVXPY` (par des solveurs comme `OSQP` ou `SCS`) tend à mieux gérer la mémoire sur les très grandes dimensions grâce à l'exploitation des matrices creuses (*sparse*), là où les solveurs classiques atteignent leurs limites physiques.




FIGURE 1 – Analyse de la complexité temporelle et scalabilité des algorithmes.

Si la section précédente a mis en lumière les contraintes algorithmiques liées à la dimensionnalité du problème, nous nous intéressons ici à la validité financière et statistique du modèle. L'approche moyenne-variance de Markowitz repose sur une hypothèse forte : la stabilité des paramètres de marché (rendements espérés μ et matrice de covariance Σ) dans le temps.

1.2 Analyse Exploratoire des Données (Stationnarité)

Avant toute tentative d'optimisation, il est crucial d'examiner la dynamique des actifs sous-jacents pour valider nos hypothèses de modélisation. La Figure 2 présente l'évolution des rendements quotidiens sur l'ensemble de la période étudiée.



FIGURE 2 – Séries temporelles des rendements historiques. La rupture de structure entre la période d'apprentissage (haut) et la crise de 2020 (bas) est manifeste.

L'analyse visuelle permet de distinguer deux régimes de volatilité radicalement opposés :

- **La phase d'apprentissage (2016-2019) :** Les rendements oscillent de manière relativement stable autour de zéro. Cette période correspond à un régime de marché "calme", propice à une estimation fiable des corrélations historiques.
- **La phase de test (2020) :** On observe une explosion de la volatilité caractérisée par des amplitudes de variation extrêmes (dépassant $\pm 10\%$ par jour). Cette rupture structurelle, causée par la crise sanitaire du COVID-19, suggère que les paramètres μ et Σ estimés sur le passé ne seront plus représentatifs de la réalité future, préfigurant l'échec des modèles statiques.

1.3 Formulation Mathématique et Résolution

Le problème classique de Markowitz cherche à minimiser la variance du portefeuille σ_p^2 sous une contrainte de rendement cible. Il s'écrit comme un programme quadratique convexe (QP) :

$$\min_{x \in \mathbb{R}^n} x^T \Sigma x \quad \text{s.c.} \quad \mu^T x \geq r_{min}, \quad \sum_{i=1}^n x_i = 1, \quad x \geq 0 \quad (1)$$

Cette formulation présente l'avantage d'être convexe, garantissant l'unicité de la solution globale (si Σ est définie positive). Cependant, comme vu en Section 1, sa résolution devient coûteuse pour n grand, nécessitant des solveurs performants.

1.4 Analyse de Robustesse et Frontière Efficiente (Monte Carlo)

Pour évaluer la qualité de la solution obtenue par optimisation quadratique, nous l'avons confrontée à une simulation de Monte Carlo générant des milliers de portefeuilles aléatoires. Cette méthode permet de visualiser l'intégralité de l'univers d'investissement possible et de tracer la frontière efficiente.

La Figure 3 compare les résultats obtenus "In-Sample" (sur les données d'entraînement) et "Out-of-Sample" (sur les données de test).




FIGURE 3 – Comparaison des frontières efficaces. L'étoile rouge indique le portefeuille optimisé. À gauche, la solution est mathématiquement optimale. À droite, elle est invalidée par le changement de régime de marché.

L'interprétation de ces graphiques conduit à deux conclusions majeures sur la gestion du risque :

1. **Validation In-Sample (Gauche) :** Sur les données historiques, le solveur fonctionne parfaitement. L'étoile rouge se situe exactement sur la frontière supérieure gauche du nuage de points. Cela confirme que l'algorithme a réussi à trouver la combinaison d'actifs offrant la variance minimale absolue pour le niveau de rendement requis. Aucun portefeuille aléatoire ne peut faire mieux.
2. **Échec Out-of-Sample (Droite) :** La situation est dramatiquement différente sur les données de 2020. Le portefeuille "optimal" (calculé sur 2016-2019) se retrouve, une fois projeté dans la réalité de 2020, "noyé" au milieu du nuage de points. Il n'est plus sur la frontière efficace.

Interprétation financière : Cela démontre la limite fondamentale de l'optimisation moyenne-variance : elle ne capture pas le risque de *changement de régime*.

De plus, on remarque que le nuage de points de 2020 est beaucoup plus dispersé et étiré que celui de 2016-2019. Cela illustre visuellement la hausse des corrélations entre actifs pendant la crise : quand tout baisse en même temps, la diversification (qui repose sur des corrélations faibles ou négatives) ne fonctionne plus.

Limites de l'approche Probabiliste Une tentative d'extension via le modèle de Markowitz probabiliste a mis en évidence les limites structurelles de l'approche Gaussienne. L'analyse de sensibilité pour $n = 20$ révèle une frontière de faisabilité stricte : le problème admet une solution optimale pour $\beta = 0.45$ (avec un rendement de 15.86% et écart-type de 10.79%), mais devient **infaisable** dès $\beta = 0.40$. Cette transition brutale souligne l'extrême sensibilité du modèle aux contraintes de probabilité (β) et confirme que le simple ajout de contraintes sur la variance ne suffit pas à gérer les risques extrêmes sans compromettre la faisabilité du problème.

Cette incapacité de la variance seule à anticiper les risques extrêmes justifie notre transition vers des mesures de risque plus sophistiquées, telles que le **Kurtosis**, qui sera l'objet de la section suivante.

2 Modélisation Avancée : Minimisation du Kurtosis


L'échec du modèle de variance minimale face à la crise de 2020 (démontré en Section 2) nous contraint à dépasser l'hypothèse de normalité des rendements. Pour capturer les événements extrêmes de type macroéconomique typiquement, nous proposons d'optimiser le moment d'ordre 4 : le **Kurtosis**.

2.1 Le Défi : La Non-Convexité du Kurtosis


Contrairement à l'optimisation de la variance où la matrice Hessienne est constante et toujours semi-définie positive (garantissant un optimum unique), la minimisation du Kurtosis repose sur une forme de degré 4.

$$\min_x x^T M_4(x \otimes x \otimes x) \quad \text{s.c.} \quad \mu^T x \geq r_{min}, \quad \sum x_i = 1, \quad x \geq 0 \quad (2)$$

La non-convexité provient de la **matrice Hessienne** de la fonction objectif. Celle-ci n'est pas constante (elle dépend quadratiquement de x) et n'est pas garantie d'être semi-définie positive sur tout l'espace admissible. L'existence potentielle de valeurs propres négatives de la Hessienne engendre des minima locaux, rendant les méthodes de descente classiques inefficaces pour trouver l'optimum global.



(a) Convergence SQP (Gradient et Pas de mise à jour)



(b) Descente monotone de la fonction de coût (SCP)

FIGURE 4 – Analyse de la convergence numérique. Haut : La norme du pas $\|dx\|$ chute exponentiellement vers 10^{-7} , indiquant l'atteinte d'un point stationnaire. Bas : La fonction objectif (proxy du Kurtosis) décroît de manière monotone, confirmant la robustesse de l'approche SCP.

2.2 Algorithme SCP (Sequential Convex Programming)

Pour contourner cette difficulté, nous avons implémenté une méthode itérative de *Programmation Séquentielle Convexe* (SCP). L'idée centrale est d'approcher le problème non-convexe par une suite de sous-problèmes convexes (SOCP ou SDP) plus simples à résoudre.

À chaque itération k , nous linéarisons la contrainte non-convexe $X = xx^T$ autour du point courant x_k :

$$X \approx x_k x_k^T + x_k \delta x^T + \delta x x_k^T \quad (3)$$

Un ajout crucial à notre implémentation a été la contrainte de **Région de Confiance** ($\|\delta x\| \leq \Delta$). Sans elle, l'approximation de Taylor ne serait valide que sur un voisinage infinitésimal, et l'algorithme divergerait.

2.3 Convergence Numérique et Validation

La stabilité de notre solveur maison est validée par l'analyse de sa convergence, illustrée en Figure 4.

Interprétation technique :

- **Graphique du haut (SQP) :** La décroissance rapide de la norme du gradient $\|\nabla f(x_k)\|$ et du pas $\|dx\|$ prouve que l'algorithme satisfait les conditions d'optimalité du premier ordre (KKT). En moins de 10 itérations, la solution se stabilise avec une précision de 10^{-7} , ce qui est remarquable et peut paraître étonnant pour un solveur implémenté par nos propres soins.
- **Graphique du bas (SCP) :** La courbe montre une réduction continue de la valeur du Kurtosis. L'absence d'oscillations ou de remontées valide le choix de la taille de la région de confiance (Δ).

Cela confirme que notre approximation locale convexe est un bon choix pour guider l'optimisation vers un minimum local de qualité.

- **Réglage de la Région de Confiance** : Un point critique lors du développement a été le réglage du paramètre Δ . Une valeur trop grande provoquait des oscillations (la linéarisation cessant d'être valide), tandis qu'une valeur trop petite ralentissait la convergence inutilement.

Comparaison technique (SQP vs SLSQP) La comparaison avec le solveur industriel `scipy.optimize` (SLSQP) apporte un éclairage technique important. Bien que le solveur SLSQP soit environ 5 fois plus rapide, notre implémentation SQP démontre une précision géométrique supérieure en saturant exactement la contrainte ($\|x\|^2 = 0.5$), là où SLSQP propose une solution à l'intérieur du domaine admissible ($\|x\|^2 \approx 0.47$). Les valeurs objectives restent cependant très proches, validant la justesse mathématique de notre algorithme.


Cette validation numérique est essentielle : elle nous assure que les résultats financiers que nous analyserons dans la section suivante (Section 4) sont le fruit d'un calcul robuste et non d'anomalies de calcul numérique.

3 Résultats Comparatifs et Allocation

Après avoir détaillé les limites de l'approche Moyenne-Variance (Section 2) et développé un algorithme SCP dédié à la minimisation du Kurtosis (Section 3), nous procédons ici à la validation finale. Cette section compare notre méthode "maison" au standard (SLSQP) et analyse la performance financière réelle des portefeuilles obtenus.


3.1 Comparaison des Allocations : Validation Croisée

Pour valider la justesse de notre implémentation SCP, nous comparons la composition du portefeuille optimal obtenu avec celle fournie par le solveur `scipy.optimize.minimize` (méthode SLSQP). La Figure 5 (suite) illustre les pondérations des portefeuilles.



(a) Allocation via notre méthode SCP

FIGURE 5 – Comparaison des stratégies d'allocation pour la minimisation du Kurtosis (Partie 1).




(b) Allocation via le solveur SLSQP

FIGURE 5 – Comparaison des stratégies d'allocation pour la minimisation du Kurtosis. La similitude des résultats entre les deux méthodes confirme la stabilité de la solution.


Analyse et Interprétation :

- **Convergence et Robustesse** : Contrairement à la crainte initiale de tomber dans des minimums locaux très différents, nous observons une forte convergence entre les deux méthodes :
 - Le solveur industriel **SLSQP** propose une allocation dominée par l'actif BAX ($\approx 49.4\%$).
 - Notre algorithme **SCP** confirme cette tendance avec une concentration encore légèrement supérieure sur BAX ($\approx 51.5\%$).
- **Validation Croisée** : La proximité structurelle des deux portefeuilles (écart inférieur à 2% sur l'actif principal) valide la justesse de notre implémentation. Les deux algorithmes identifient la même stratégie optimale.
- **Interprétation de la convergence** : Cette ressemblance s'explique simplement : avec seulement 3 actifs et des contraintes strictes à respecter (budget et rendement cible), le choix de portefeuilles possibles est très réduit. Il est donc logique que les deux algorithmes finissent par trouver la même solution. C'est surtout une excellente validation pour nous : cela prouve que notre code fonctionne aussi bien que le solveur standard.

Analyse Monte Carlo des solutions Pour vérifier le positionnement de nos solutions dans l'univers risque-rendement, nous avons projeté le portefeuille Kurtosis (SCP) et le portefeuille Markowitz sur un nuage de points Monte Carlo.



(a) Solution Markowitz (Variance Min)



(b) Solution Kurtosis (SCP)

FIGURE 6 – Visualisation des portefeuilles optimaux au sein de l'univers Monte Carlo. L'étoile rouge indique la solution calculée. On observe que la solution Kurtosis (droite) accepte une variance légèrement supérieure à la solution Markowitz (gauche) pour minimiser les moments d'ordre 4.

3.2 Performance Financière : L'Épreuve de Réalité

Au-delà de la réussite mathématique, la question cruciale reste financière : *la minimisation du Kurtosis a-t-elle permis de protéger le portefeuille contre le krach de 2020, là où Markowitz a échoué ?*

La Figure 7 compare les rendements annualisés des stratégies sur les périodes d'entraînement (In-Sample) et de test (Out-of-Sample).




FIGURE 7 – Comparaison des rendements annualisés. Gauche : Performances In-Sample (Train). Droite : Performances Out-of-Sample (Test 2020). L'effondrement des rendements en phase de test est généralisé.

Bilan Financier :

1. **Performance In-Sample (Satisfaisante) :** Sur la période 2016-2019, les deux portefeuilles (Markowitz et Kurtosis SLSQP) génèrent des rendements solides, proches de **20%**. Ils respectent la contrainte $r \geq r_{min}$ imposée dans le modèle, tout en minimisant les risques théoriques.
2. **Performance Out-of-Sample (Dégradation marquée) :** Sur l'année 2020, les rendements s'effondrent littéralement pour tomber aux alentours de **4%**. Bien que restant positifs, ils sont divisés par 5 par rapport à la période d'entraînement.

Lien avec la Section 2 : Ce résultat fait écho aux limites observées précédemment. Même en optimisant le Kurtosis pour réduire les événements de type extrême, le modèle reste tributaire des données historiques. La crise du COVID-19 a été un événement systémique d'une telle ampleur que les propriétés statistiques passées n'ont pas permis de maintenir les niveaux de rendement espérés, bien qu'elles aient évité des pertes négatives.

Extension post-crise 2020-2021 Il est crucial de nuancer l'échec observé en 2020 par l'analyse de la période étendue 2020-2021. L'inclusion de l'année 2021 montre une nette amélioration des métriques hors échantillon, avec un rendement moyen bondissant de 0.36% à 4.05% et une baisse significative de la volatilité. Ce rebond confirme que la sous-performance de 2020 est davantage liée à une rupture soudaine du marché (crise sanitaire) qu'à une invalidité intrinsèque du modèle d'optimisation.

Conclusion : L'optimisation avancée (Kurtosis) apporte une robustesse théorique supplémentaire par rapport à la variance, mais elle ne constitue pas une assurance tous risques contre les changements de régime macroéconomiques (krach boursier, crise sanitaire...). Cela souligne la nécessité de coupler ces méthodes d'optimisation avec des approches prédictives (Machine Learning) ou de gestion dynamique des risques.

4 Approche par Relaxation Convexe (SDP)

Face à la difficulté des méthodes non-convexes (SCP) qui peuvent rester bloquées dans des minimums locaux, nous explorons ici une approche par relaxation convexe Semidefinite Programming (SDP).

4.1 Relation Théorique

Le problème original de minimisation du Kurtosis (Eq. 5) impose la contrainte non-convexe $X = xx^T$. La relaxation convexe (Eq. 10) remplace cette égalité par une inégalité matricielle via le complément de Schur :

$$\begin{bmatrix} X & x \\ x^T & 1 \end{bmatrix} \succeq 0 \iff X \succeq xx^T \quad (4)$$

Relation entre les problèmes : Le problème relaxé (10) est une version "moins contrainte" du problème (5). Par conséquent, l'ensemble des solutions admissibles est plus grand.

- La valeur optimale du problème relaxé est toujours **inférieure ou égale** à celle du problème original (Borne inférieure).

- Si la solution optimale du problème relaxé vérifie $X = xx^T$ (c'est-à-dire si la matrice X est de rang 1), alors cette solution est aussi l'optimum global du problème original.

4.2 Résultats et Qualité de la Relaxation

Nous avons résolu le problème relaxé avec **CVXPY** (qui gère nativement les contraintes SDP).

Comparaison de performance : En termes de temps de calcul, la résolution SDP est structurellement plus coûteuse que le SQP pour de grandes dimensions (n) car le nombre de variables augmente quadratiquement (n^2 variables pour la matrice X), contre linéairement pour le SQP.

Pour $n = 20$ actifs, le temps de résolution passe de **0.0062s** (Markowitz standard) à **0.2342s** (SDP), confirmant le surcoût computationnel. Cependant, cette méthode offre l'avantage théorique majeur de la convexité. Plus important encore, nous avons vérifié la qualité de la relaxation en calculant la norme de l'erreur $\|X - xx^T\|$. Pour $n = 20$, cette erreur est de **2.2574e-05**, ce qui indique que la relaxation est **quasi-exacte** dans ce cas pratique. La solution trouvée est donc certifiée comme étant l'optimum global du problème (ou extrêmement proche).

5 Conclusion

Ce projet a couvert la chaîne complète de l'optimisation de portefeuille, de la théorie à l'implémentation numérique.

Bilan Technique

Nous avons validé la supériorité des algorithmes décomposés pour les grandes dimensions, face à la complexité cubique des solveurs standards. Notre implémentation SCP (*Sequential Convex Programming*) a démontré sa robustesse : grâce à la régularisation par région de confiance, elle atteint une précision de 10^{-7} et surmonte la non-convexité intrinsèque de la minimisation du Kurtosis.

Bilan Financier

L'épreuve du krach de 2020 livre un enseignement crucial : si l'optimisation du Kurtosis réduit théoriquement les risques extrêmes, elle reste vulnérable à la *non-stationnarité*. Les modèles fondés sur l'historique subissent un sur-ajustement et échouent face aux ruptures systémiques du marché, soulignant que l'optimisation mathématique ne remplace pas la gestion dynamique du risque.

Perspectives

L'avenir réside dans le couplage entre optimisation et Machine Learning. Plutôt que d'optimiser sur le passé, l'enjeu est d'utiliser des modèles prédictifs (Réseaux de neurones, Auto-encodeurs) pour estimer des paramètres prospectifs ($\hat{\mu}, \hat{\Sigma}$) et anticiper les changements de régime.